

دانشگاه — قالب حرفه‌ای سند دانشگاهی

ترجمه و بازنویسی علمی فارسی با صفحه‌آرایی راست‌به‌چپ


طراحی تولید مجموعه‌داده مصنوعی و پیش‌پردازش — سند مشخصات

ترجمه تخصصی در حوزه علوم کامپیوتر، هوش مصنوعی و مهندسی
نرم‌افزار

نوع سند: مشخصات طراحی

تاریخ بازبینی: ۰۱-۰۷-۲۰۲۶

زبان: فارسی



فهرست مطالب

۱	زمینه
۱	یادداشت‌های بازنگری
۲	ناسازگاری شناخته‌شده در پروپوزال
۲	انطباق با استاندارد SEMAT
۳	اهداف
۳	خارج از دامنه
۴	رده‌بندی تخصص‌ها
۵	ساختار پروژه
۶	گام ۱ — تولید پژوهشگر
۸	گام ۲ — تولید پروژه
۱۲	گام ۳ — تخصیص نقش‌ها
۱۳	گام ۴ — پیش‌پردازش
۱۴	اعتبارسنجی
۱۵	وابستگی‌ها
۱۵	برآورد هزینه

زمینه

این سند، فاز نخست پایان‌نامه مصوب کارشناسی ارشد با عنوان «ارائه یک سیستم پیشنهاددهنده هوشمند برای تخصیص پروژه‌های پژوهشی به مجریان...» را تشریح می‌کند. مطابق نمودار گانتِ پروپوزال مصوب، نخستین گام اجرایی پس از تصویب پروپوزال عبارت است از: **ساخت مجموعه داده مصنوعی و پیش‌پردازش متون** که برای آن بازه زمانی دوماهه در نظر گرفته شده است.

یادداشت‌های بازنگری (۲۰۲۶-۰۷-۰۱)

1. تخصص‌ها باید زیرحوزه‌هایی به هم پیوسته از علوم کامپیوتر، هوش مصنوعی و مهندسی نرم‌افزار باشند و هیچ حوزه نامرتبیطی مانند پزشکی، اقتصاد یا مکانیک در آن‌ها وارد نشود. همچنین تعداد تخصص‌ها باید دقیقاً ۱۰ مورد باشد.
 2. مقیاس داده باید به ۱۰۰ پژوهشگر، یعنی ۱۰ پژوهشگر در هر تخصص، و حدود ۱۳۰۰ پروژه افزایش یابد.
 3. همه پژوهشگران نباید الزاماً تک‌تخصصی باشند؛ توزیع چندتخصصی باید به صورت تجمعی تعریف شود.
 4. تخصص هر پژوهشگر باید بر پایه هم‌زمانِ خوداظهاری و شواهد تجربیِ برگرفته از سابقه پروژه‌ها تعیین شود، نه صرفاً بر اساس خوداظهاری.
 5. هر پروژه باید علاوه بر عنوان و چکیده، محتوای غنی‌تری شامل مقدمه/بیان مسئله، مرور ادبیات، خلاصه روش‌شناسی و خلاصه نتایج داشته باشد.
 6. برای هر پروژه باید نقش‌های «مجری»، «ناظر» و «همکار» تعریف شود و ساختار داده به نقش مجری محدود نماند.
- سطوح دشواری (آسان/متوسط/سخت) حفظ می‌شوند، اما تعریف آن‌ها متناسب با ساختار جدید چندتخصصی بازتنظیم می‌شود.
 - فیلد `specialty_weights` یک فیلد مشتق‌شده پسینی است که پس از تولید همه پروژه‌ها محاسبه می‌شود و در زمان تولید پژوهشگران مقداردهی نخواهد شد.

ناسازگاری شناخته شده در پروپوزال (رفع شده)

توصیف مرحله به مرحله روش شناسی در پروپوزال (۵۰ پژوهشگر $\times$ ۳ پروژه = ۱۵۰) با بخش مربوط به حجم نمونه (۵۰۰ پروژه، حدود ۱۶۷ پروژه در هر سطح دشواری) همخوانی ندارد. با توجه به افزایش مقیاس مورد نظر استاد راهنما به ۱۰۰ پژوهشگر و حدود ۱۳ پروژه برای هر پژوهشگر، این ناسازگاری دیگر موضوعیت ندارد. هدف نهایی به صورت ۱۰۰ پژوهشگر $\times$ ۱۳ پروژه در نقش مجری = ۱۳۰۰ پروژه تثبیت شده است.

انطباق با استاندارد SEMAT

- `PERSON_RESEARCHINTEREST` / `..._KEYWORD` : علایق پژوهشی مبتنی بر کلیدواژه برای پژوهشگر که با الگوی طراحی کلیدواژه‌های این طرح سازگار است.
- `PERSON_EXPERTISEANDSKILLS` / `..._KEYWORD` : مهارت‌ها و تخصص‌ها در قالب کلیدواژه که از همان الگوی ساختاری پیروی می‌کند.
- `PERSON_OU.CLAS_ID_SLVL` : مرتبه علمی به صورت کد واژگان کنترل شده تعریف می‌شود؛ در نتیجه، فیلد `academic_rank` از مقادیر مربی، استادیار، دانشیار و استاد استفاده می‌کند.
- `PROJECT_PERSON.CLAS_ID_ROLE` : کد نقش افراد در پروژه را مشخص می‌کند؛ بنابراین، نقش‌های مجری، ناظر و همکار به گونه‌ای تعریف می‌شوند که با توسعه‌های بعدی پایان‌نامه سازگار باشند.

اهداف

- تولید یک مجموعه داده مصنوعی باز، بازتولیدپذیر و فارسی‌زبان شامل حدود ۱۳۰۰ پروژه پژوهشی که به ۱۰۰ پژوهشگر مجازی تخصیص یافته‌اند، به نحوی که از نظر ساختاری بر مدل SEMAT تکیه داشته و برای آزمایش‌های تطبیق معنایی مبتنی بر LLM به اندازه کافی غنی باشد.
- تولید نسخه‌ای پاک‌سازی شده و پیش‌پردازش شده از متون پروژه‌ها برای استفاده در مرحله بعدی استخراج تعبیه‌ها.
- حفظ ماژولار بودن کد تولید داده و قابلیت اجرای آن از طریق یک نوت‌بوک میزبانی شده در Kaggle.

خارج از دامنه

- تفکیک داده به مجموعه‌های آموزش و آزمون.
- استخراج تعبیه‌ها، محاسبه شباهت و معیارهای ارزیابی.
- هرگونه استفاده از داده‌های واقعی پژوهشگران؛ ارجاع به SID یا IranDoc صرفاً برای الهام‌گیری در سبک انجام می‌شود.

رده‌بندی تخصص‌ها (۱۰ حوزه)

همه حوزه‌ها از زیرشاخه‌های علوم کامپیوتر هستند و میان آن‌ها هم‌پوشانی معنادار دوجانبه وجود دارد؛ بنابراین، امکان شکل‌گیری پروژه‌های میان‌رشته‌ای واقع‌گرایانه در سطح سخت فراهم می‌شود.

ردیف	حوزه (فارسی)	حوزه‌های مجاور
۱	یادگیری ماشین و داده‌کاوی	۲، ۳، ۴، ۱۰
۲	پردازش زبان طبیعی	۱، ۴
۳	بینایی ماشین و پردازش تصویر	۱، ۴
۴	هوش مصنوعی و سیستم‌های خبره	۱، ۲، ۳
۵	امنیت سایبری و رمزنگاری	۷، ۸
۶	مهندسی نرم‌افزار و معماری سیستم	۸، ۹
۷	شبکه‌های کامپیوتری و انتقال داده	۵، ۸، ۹
۸	رایانش ابری و سیستم‌های توزیع‌شده	۶، ۷، ۹
۹	اینترنت اشیاء و سیستم‌های نهفته	۷، ۸

ردیف	حوزه (فارسی)	حوزه‌های مجاور
۱۰	پایگاه داده و بازیابی اطلاعات	۶، ۴، ۱

برای هر حوزه، یک بانک کلیدواژه شامل حدود ۲۰ کلیدواژه نامزد و نیز الگوهای تولید عنوان در فایل `src/config.py` تعریف می‌شود.

ساختار پروژه

```
D:\Projects\payan\
├─ data/
│   └─ raw/
│       ├── researchers.csv          # 100 virtual researchers
│       ├── projects.csv             # ~1300 generated projects (rich content)
│       └─ project_assignments.csv   # researcher-project role mapping
│   └─ processed/
│       └─ projects_clean.csv        # projects.csv + clean_text column
├─ src/
│   ├── config.py                   # taxonomy, keyword banks, templates, paths, RN
│   ├── researchers.py              # generate_researchers() - no LLM
│   ├── projects.py                 # generate_projects() - GPT-4o, two-phase
│   ├── assignments.py              # assign_roles() - no LLM
│   └─ preprocess.py                # normalize / tokenize / stopword-remove (Hazm)
├─ notebooks/
│   └─ 01_build_dataset.ipynb       # orchestrator, Kaggle-compatible
├─ tests/
│   └─ test_dataset.py
├─ requirements.txt
├─ .env.example                     # OPENAI_API_KEY=...
└─ README.md
```

منطق تولید داده در پوشه `/src` قرار می‌گیرد تا آزمون‌پذیر، قابل مقایسه و مناسب بازیابی باشد؛ در مقابل، نوت‌بوک صرفاً نقش هماهنگ‌کننده اجرا و ذخیره‌سازی خروجی را بر عهده دارد.

گام ۱ — تولید پژوهشگر (src/researchers.py)

در این بخش هیچ فراخوانی به LLM انجام نمی‌شود و همه چیز بر پایه تصادفی‌سازی کنترل‌شده و بزرگداری‌شده پیش می‌رود.

توزیع چند تخصصی

گروه	تعداد	تعداد تخصص
تک تخصصی	۷۰	۱
دو تخصصی	۱۰	دقیقاً ۲
سه تخصصی	۱۰	دقیقاً ۳
چهار تخصصی	۵	دقیقاً ۴
پنج تخصصی	۵	دقیقاً ۵
جمع	۱۰۰	

تخصص‌های افزوده‌شده فراتر از تخصص اصلی، از فهرست حوزه‌های مجاور نمونه‌گیری می‌شوند تا هم‌پوشانی موضوعیِ واقع‌گرایانه حفظ شود.

خوداظهاری در برابر تخصص تجربی

- `self_declared_specialties` : فهرستی از حوزه‌هایی که پژوهشگر صراحتاً ادعا می‌کند در آن‌ها تخصص دارد؛ این فهرست در زمان تولید پژوهشگر و پیش از تولید هرگونه پروژه تعیین می‌شود.
- `specialty_weights` : یک امتیاز وابسته به هر حوزه که بازتاب‌دهنده سابقه واقعی پروژه‌های پژوهشگر است. این فیلد پس از تولید همه پروژه‌ها محاسبه شده و سپس در فایل `researchers.csv` ثبت می‌شود.

```
weight[domain] = (projects_as_manager_in_domain) / (total_projects_as_manager_in_domain)
```

این سازوکار، امکان تعریف سطح دشواری «سخت» را فراهم می‌سازد؛ به این معنا که یک پژوهشگر می‌تواند در حوزه‌ای که در `self_declared_specialties` خود ذکر نکرده است، مقدار غیرصفر در `specialty_weights` داشته باشد.

شمای خروجی (data/raw/researchers.csv)

فیلد	منبع / توضیح
researcher_id	از Researcher_001 تا Researcher_100
name	نام مستعار: از پژوهشگر_001 تا پژوهشگر_100
academic_rank	نمونه‌گیری از مجموعه {مربی، استادیار، دانشیار، استاد} با وزن بیشتر به استادیار/دانشیار
university	نام مستعار دانشگاه: از دانشگاه_A تا دانشگاه_J
department	مشتق‌شده از تخصص اصلی
self_declared_specialties	نام حوزه‌ها با جداکننده \
research_keywords	۵ کلیدواژه برای هر تخصص اظهارشده، با جداکننده \
paper_titles	۱۵ عنوان تولیدشده بر اساس الگوهای عنوان، با جداکننده \
specialty_weights	هنگام تولید اولیه خالی است؛ پس از گام ۲ تکمیل می‌شود
num_papers	مقدار ثابت ۱۵
topic_diversity	امتیاز تصادفی کنترل‌شده بین ۰ تا ۱
activity_index	امتیاز تصادفی کنترل‌شده بین ۰ تا ۱ برای فعالیت پژوهشی اخیر

گام ۲ — تولید پروژه (src/projects.py ، با GPT-4o)

تعداد پروژه و منطق تخصیص

هر پژوهشگر دقیقاً در ۱۳ پروژه نقش مجری را بر عهده می‌گیرد. علاوه بر این، در بیشتر پروژه‌ها یک ناظر و/یا همکار نیز از میان دیگر پژوهشگران تخصیص داده می‌شود. عدد ۱۳۰۰، تعداد پروژه‌ها را بر اساس انتساب نقش مجری نشان می‌دهد.

سطوح دشواری

سطح	تعریف	چالش تطبیق
آسان	پروژه در تخصص اصلی اظهارشده پژوهشگر قرار دارد و کلیدواژه‌های فهرست او مستقیماً در متن بازاستفاده می‌شوند	خط مبنای TF-IDF کفایت می‌کند
متوسط	پروژه در تخصص ثانویه اظهارشده پژوهشگر است، یا در تخصص اصلی اما با جابه‌جایی واژگانی؛ بدون اشتراک مستقیم کلیدواژه و صرفاً با بازنویسی معنایی	نیازمند درک معنایی فراتر از تطبیق کلیدواژه‌ای است
سخت	پروژه دو تخصص مجاور پژوهشگر را با هم ترکیب می‌کند، یا در حوزه‌ای قرار می‌گیرد که در سابقه پروژه‌ای او دیده می‌شود اما در خوداظهاری او حضور ندارد	مستلزم استنباط از سابقه پژوهشی است

توزیع هر پژوهشگر در ۱۳ پروژه

سطح دشواری	تعداد	توضیح
آسان	۵	تخصص اصلی با استفاده مستقیم از کلیدواژه‌ها
متوسط	۵	تخصص ثانویه، یا تخصص اصلی با بازنویسی مفهومی

سطح دشواری	تعداد	توضیح
سخت	۳	پروژه بین‌حوزه‌ای یا مبتنی بر سابقه بدون خوداظهاری

در مجموع، برای ۱۰۰ پژوهشگر خواهیم داشت: ۵۰۰ پروژه آسان + ۵۰۰ پروژه متوسط + ۲۰۰ پروژه سخت = ۱۲۰۰ پروژه.

تولید دومرحله‌ای با GPT-4o

تولید ۱۲۰۰ پروژه با ۶ بخش محتوایی غنی در یک اعلان واحد برای هر پروژه، از نظر طول زمینه و هزینه، بهینه نیست. بنابراین، رویکرد دومرحله‌ای زیر اتخاذ می‌شود.

فاز A — تولید هسته پروژه

```
{
  "title": "...",
  "abstract": "... (100-150 words)",
  "keywords": ["...", "..."],
  "specialty_domain": "..."
}
```

فاز B — بسط بخش‌ها

```
{
  "introduction": "... (80-120 words)",
  "literature_review": "... (80-120 words)",
  "methodology_summary": "... (60-80 words)",
  "results_summary": "... (60-80 words)"
}
```

در نتیجه، مجموع فراخوانی‌ها حدود $۱۲۰۰ \times ۲ = ۲۴۰۰$ خواهد بود. برآورد هزینه با قیمت‌گذاری GPT-4o کمتر از ۱۵ دلار است.

- **آسان:** «از کلیدواژه‌های دقیق پژوهشگر در متن استفاده کن.»
 - **متوسط:** «مفهوماً در حوزه تخصصی پژوهشگر بمان ولی از کلیدواژه‌های مستقیم استفاده نکن.»
 - **سخت:** «پروژه‌ای بین حوزه‌ای بنویس که حوزه‌های [A] و [B] را ترکیب کند.»
- همه فراخوانی‌ها با حالت خروجی JSON ساخت‌یافته انجام می‌شوند و فایل `projects.py` پس از تولید هر پروژه، خروجی را به صورت افزایشی در CSV ثبت می‌کند.

شمای خروجی (`data/raw/projects.csv`)

فیلد	توضیح
<code>project_id</code>	شناسه ترتیبی از <code>PRJ_0001</code> تا <code>PRJ_1300</code>
<code>title</code>	عنوان تولیدشده به زبان فارسی
<code>specialty_domain</code>	حوزه اصلی پروژه
<code>abstract</code>	چکیده تولیدشده به زبان فارسی، حدود ۱۰۰ تا ۱۵۰ واژه
<code>introduction</code>	مقدمه به همراه بیان مسئله، حدود ۸۰ تا ۱۲۰ واژه
<code>literature_review</code>	خلاصه پیشینه و کارهای پیشین، حدود ۸۰ تا ۱۲۰ واژه
<code>methodology_summary</code>	مرور فشرده روش، حدود ۶۰ تا ۸۰ واژه
<code>results_summary</code>	جمع‌بندی یافته‌ها/دستاوردها، حدود ۶۰ تا ۸۰ واژه
<code>keywords</code>	کلیدواژه‌های تولیدشده، با جداکننده <code>\ </code> و بین ۳ تا ۷ مورد
<code>manager_id</code>	کلید خارجی به <code>researchers.csv</code> برای نقش مجری
<code>difficulty</code>	یکی از <code>easy</code> ، <code>medium</code> یا <code>hard</code>
<code>year</code>	سال مصنوعی در بازه ۱۳۹۵ تا ۱۴۰۳ هجری شمسی

گام ۳ — تخصیص نقش‌ها (src/assignments.py)

پس از تولید هر ۱۳۰۰ پروژه، نقش‌های ناظر و همکار به پروژه‌ها تخصیص داده می‌شوند. در این بخش نیز از LLM استفاده نمی‌شود و کل فرآیند کاملاً قاعده‌منا و مبتنی بر انتخاب از مخزن پژوهشگران است.

سناریو	درصد	تعداد
مجری + ناظر	۵۵٪	حدود ۷۱۵ پروژه
مجری + ناظر + ۱ همکار	۳۰٪	حدود ۳۹۰ پروژه
فقط مجری	۱۵٪	حدود ۱۹۵ پروژه

- **ناظر:** باید دارای `academic_rank` در مجموعه {دانشیار، استاد} باشد؛ همچنین باید حوزه پروژه را در تخصص‌های اظهارشده خود یا در حوزه‌های مجاور آن داشته باشد؛ و نمی‌تواند همان فرد مجری باشد.
- **همکار:** از میان پژوهشگرانی انتخاب می‌شود که تخصص آن‌ها با حوزه پروژه مجاور است؛ مرتبه علمی می‌تواند هر مقداری باشد؛ و آن فرد نباید در همان پروژه نقش مجری یا ناظر را داشته باشد.

شمای خروجی (data/raw/project_assignments.csv)

فیلد	توضیح
<code>project_id</code>	کلید خارجی به <code>projects.csv</code>
<code>researcher_id</code>	کلید خارجی به <code>researchers.csv</code>
<code>role</code>	یکی از «مجری»، «ناظر» یا «همکار»

گام ۴ — پیش‌پردازش (src/preprocess.py ، با Hazm)

پیش‌پردازش بر روی الحاقِ فیلدهای title + abstract + introduction + literature_review + methodology_summary + results_summary برای هر پروژه اعمال می‌شود.

1. نرمال‌سازی نویسه‌ها، شامل یکسان‌سازی ی/ی و ک/ک و حذف اعراب، با استفاده از Hazm Normalizer .

2. توکن‌سازی واژگان با استفاده از Hazm.

3. حذف ایست‌واژه‌ها با تکیه بر فهرست استاندارد Hazm به‌علاوه یک فهرست تکمیلی دستی حدوداً ۵۰ واژه‌ای.

4. اتصال دوباره خروجی به‌صورت یک رشته یگانه در ستون clean_text .

- ردیف‌هایی که هر یک از فیلدهای abstract ، title یا keywords را نداشته باشند، حذف می‌شوند.

- ردیف‌های تکراری بر پایه تطابق دقیق title حذف می‌شوند.

خروجی نهایی: data/processed/projects_clean.csv که همان projects.csv به‌همراه ستون clean_text است.

اعتبارسنجی (tests/test_dataset.py)

- researchers.csv : دقیقاً ۱۰۰ ردیف داشته باشد؛ همه فیلدهای الزامی غیرتهی باشند؛
- specialty_weights مجموع برای هر پژوهشگر برابر ۱/۰ باشد؛ و توزیع ۷۰/۱۰/۱۰/۵/۵ رعایت شود.
- projects.csv : دقیقاً ۱۳۰۰ ردیف داشته باشد؛ تعداد سطوح دشواری ۵۰۰/۵۰۰/۳۰۰ باشد؛
- هر manager_id معتبر باشد؛ و هر پژوهشگر دقیقاً در ۱۳ پروژه نقش مجری داشته باشد.
- project_assignments.csv : هر project_id دقیقاً یک ردیف با نقش مجری داشته باشد؛ محدودیت مرتبه علمی ناظر رعایت شود؛ و هیچ پژوهشگری در یک پروژه دوبار ظاهر نشود.
- projects_clean.csv : هیچ عنوان تکراری و هیچ clean_text خالی نداشته باشد.

وابستگی‌ها

بسته‌های `pytest` و `openai` ، `pandas` ، `numpy` ، `hazm` ، `python-dotenv` (برای توسعه) در فایل `requirements.txt` ثبت می‌شوند.

برآورد هزینه

مؤلفه	تعداد فراخوانی	هزینه تخمینی
فاز A (تولید هسته)	۱۳۰۰	حدود ۴ دلار
فاز B (بسط بخش‌ها)	۱۳۰۰	حدود ۹ دلار
جمع کل	۲۶۰۰	حدود ۱۳ دلار

این نسخه با چیدمان راست‌به‌چپ، قلم `Vazirmatn`، جدول‌های قالب‌بندی‌شده، کدبلاک‌های تک‌فاصله، حاشیه‌های ثابت و ساختار سند دانشگاهی طراحی شده است تا برای تبدیل به PDF و DOCX مناسب باشد.